

Comportamiento del precio en autos nuevos y usados en la plataforma europea AutoScout24 durante el año 2019

Nelson Mauricio García López
Departamento de Ingeniería de electrónica
Universidad de Antioquia, Colombia
nelson.garcia@udea.edu.co

Resumen—Se realiza un análisis exploratorio, estadístico y multivariado sobre un conjunto de datos de vehículos usados con el propósito de identificar los factores más relevantes que influyen en el precio, realizando la caracterización y comportamiento de las variables que intervienen.

El proceso incluyó análisis univariado, bivariado, multivariado, correlaciones, análisis de componentes principales (PCA), análisis factorial y métodos de agrupamiento jerárquico y no jerárquico (k-means). Además, se aplicaron técnicas de detección de valores atípicos mediante IQR, Z-Score y DBSCAN y por último la limpieza de la base de datos con la eliminación de valores repetidos y en transformaciones se realizó el logaritmo para estabilizar el comportamiento de las variables.

Los resultados muestran que variables técnicas continuas como la potencia, peso del vehículo y kilometraje tienen una mayor relación con el precio. la variable categórica de combustible es importante en el análisis, por ende, se realiza transformación a discreta. El PCA reveló que los dos primeros componentes explican más del 70% de la variabilidad, confirmando patrones de estructura interna. Finalmente, se concluye que el mercado de autos usados presenta comportamientos diferenciados por características técnicas y de uso, lo cual es clave para análisis posteriores de predicción o segmentación, según el modelo implementado.

Palabras clave: análisis exploratorio, PCA, clúster, correlaciones, valores atípicos.

I. INTRODUCCIÓN

El precio de los automóviles, tanto nuevos como usados es un indicador importante en el mercado automotriz, puesto que refleja las condiciones técnicas y de uso del vehículo. El mercado de vehículos usados se ha convertido en un área de estudio relevante debido a su crecimiento y a la disponibilidad de grandes volúmenes de datos que permiten comprender la dinámica de precios, uso, desgaste y características técnicas de los automóviles. El análisis de datos aplicado a este tipo de mercados es fundamental para identificar patrones, mejorar la toma de decisiones y construir modelos predictivos robustos.

Analizar qué elementos determinan el valor de un auto es primordial, ya que permite a compradores y vendedores tomar decisiones más acertadas, a las empresas del sector diseñar

estrategias comerciales más competitivas y a los analistas económicos entender mejor la dinámica del mercado.

Los aspectos más relevantes en el análisis de mercado, para evaluar el precio final de un auto son: kilometraje, años de uso, la marca y el modelo, el tipo de combustible, la potencia del motor y el estado general del vehículo. El análisis de cada ítem mencionado y de cómo interactúan entre sí, es de vital importancia para el estudio, especialmente en plataformas de compraventa en línea como AutoScout24, que concentran gran cantidad de información sobre precios reales de mercado [1].

La base de datos fue seleccionada de Car Price disponible en la plataforma Kaggle. Este dataset recopila información de vehículos nuevos y usados ofertados en la compañía europea AutoScout24 durante el año 2019. Incluye variables técnicas y comerciales relevantes como la marca, modelo, años de uso, kilometraje, tipo de combustible, potencia del motor, transmisión, entre otras [2].

Mediante las variables disponibles en la base datos, es posible analizar cuáles de estas características se asocian de manera más significativa con el precio final de los autos, lo que permite responder a la pregunta de investigación planteada: **¿Cuáles son las principales variables que influyen en el precio de los autos publicados en la plataforma AutoScout24 durante el año 2019?** y aportar evidencia sobre los factores que más influyen en la valoración del mercado automotriz.

Este proyecto tiene como objetivo realizar un análisis estadístico completo del conjunto de datos de autos usados, abarcando técnica descriptiva, análisis bivariado, multivariado, reducción de dimensionalidad mediante PCA, análisis factorial, pruebas de asociación en variables categóricas, detección de valores atípicos, de limpieza y transformaciones de los datos.

Los objetivos específicos de este estudio comprenden depurar y preparar el conjunto de datos proveniente de la plataforma AutoScout24 mediante técnicas propias de la ciencia de datos, identificando valores atípicos, datos faltantes e inconsistencias. Además, aplicar técnicas de análisis descriptivo y multivariado para identificar las propiedades de los datos y posibles relaciones entre variables y reducir dimensionalidad.

Y, por último, Implementar transformaciones que permitan una mejor interpretación de los datos.

Con estos objetivos se busca corroborar factores de comportamientos conocidos como que el kilometraje de un auto tiene una relación negativa con el precio: a mayor kilometraje, menor precio.

Los autos con menos años tienden a presentar precios más altos que los de más años de uso, el tipo de combustible (gasolina vs. diésel) influye en el precio del vehículo y por último la transmisión automática podría estar asociada a precios más altos que la mecánica.

Algunos autores han abordado el tema de la predicción de precios de automóviles usados desde enfoques estadísticos y de aprendizaje automático. En su estudio Using Linear Regression for Used Car Price Prediction, Muti y Yildiz demostraron que la regresión lineal múltiple puede explicar una proporción significativa de la variabilidad del precio, siempre que se realice una adecuada depuración y selección de variables, y que se controle la multicolinealidad entre ellas [3].

Por su parte, Kumar y Sinha compararon distintas técnicas de regresión, incluyendo la regresión polinómica y la regresión Ridge, concluyendo que la combinación de ingeniería de características y validación cruzada permite obtener mejores niveles de precisión [4].

Turan, en Analysis of Circular Price Prediction Strategy for Used Electric Vehicles, propuso un enfoque alternativo de predicción circular aplicado a vehículos eléctricos, integrando variables dinámicas de batería y eficiencia energética, destacando la importancia de la selección de variables y la optimización iterativa de los modelos [5].

De manera complementaria, el estudio Machine Learning for Predicting Used Car Resale Prices Using Granular Vehicle Equipment Information empleó técnicas avanzadas de aprendizaje automático como árboles de decisión, máquinas de soporte vectorial (SVM) y redes neuronales, demostrando que el nivel de granularidad en la información técnica y de equipamiento mejora notablemente la exactitud de las predicciones [6].

Finalmente, el reporte elaborado por Grand View Research evidenció que el mercado de vehículos usados presenta alta variabilidad debido a la falta de estandarización en la valoración de automóviles [1].

II. METODOLOGÍA

2.1. Fuente y características del conjunto de datos

La base de datos utilizada fue de Car Price disponible en la plataforma Kaggle. Esta base de datos de autos usados se encuentra en formato CSV con 15.915 observaciones, y contiene variables continuas como: el precio del vehículo, el kilometraje recorrido, potencia, cilindraje, peso y el consumo de combustible. Por su parte en variables categóricas incluye: la marca y modelo del automóvil, el tipo de carrocería, el tipo general de vehículo, el tipo de combustible que utiliza, el tipo de transmisión, así como los distintos niveles o paquetes de comodidad, entretenimiento, extras y seguridad que posee. También se consideran categóricas discretas como la información sobre si el vehículo cuenta con inspección vigente, número de marchas, edad del vehículo y el número de dueños anteriores.

TABLA I
VARIABLES SELECCIONADAS

Variable	Tipo de variable	Definición
price	Continua	Valor de los automóviles en Euros
km	Continua	Kilómetros recorridos por el vehículo
Fuel	Cualitativa	Tipo de combustible utilizado
Gears	Discreta	El número de marchas en la transmisión del vehículo
age	Discreta	Edad del vehículo (calculada en función del año del modelo).
Previous_Owners	Discreta	El número de propietarios anteriores que ha tenido el coche.
hp_kW	Continua	Potencia del motor en kilowatts (kW)
Inspection_new	Discreta	Indica si el vehículo ha sido inspeccionado recientemente (1 para sí, 0 para no).
Displacement_cc	Continua	El motor en centímetros cúbicos (cc), indica el tamaño del motor.
Weight_kg	Continua	Peso del auto en Kilogramos
cons_comb	Continua	El consumo de combustible en litros por cada 100 kilómetros.

Entre las variables seleccionadas para su estudio y análisis se encuentran las observadas en la tabla 1, donde se realiza su definición y su unidad de medida y el tipo de variable ya sea continua o discreta.

Para iniciar el análisis nos centramos en las variables continuas:

TABLA II
VARIABLES CONTINUAS

Variable	Tipo de variable	Definición
price	Continua	Valor de los automóviles en Euros
km	Continua	Kilómetros recorridos por el vehículo
hp_kW	Continua	Potencia del motor en kilowatts (kW)
Displacement_cc	Continua	El motor en centímetros cúbicos (cc), indica el tamaño del motor
Weight_kg	Continua	Peso del auto en Kilogramos
cons_comb	Continua	El consumo de combustible en litros por cada 100 kilómetros

2.2. Técnicas de análisis aplicadas

Para el análisis de la base datos utilizada se utilizó varias técnicas para determinar el comportamiento de las variables:

- **Análisis univariado:** cada variable se interpretó con medidas de tendencia central, como son la media, la mediana y moda; se identificó la distribución de los datos mediante los histogramas, e identificar los valores atípicos con los boxplots.

- **Análisis bivariado:** en este apartado es importante conocer la matriz de correlaciones para las variables continuas mediante las correlaciones Pearson y Spearman, y se realizaron pruebas Chi-cuadrado para las variables categóricas.
- **Análisis multivariado:** con el objetivo de disminuir la dimensionalidad de las variables se utilizaron las siguientes técnicas: PCA para reducción de dimensiones, Clúster jerárquico y K-Means, análisis factorial y regresión lineal.
- **Detección y tratamiento de valores atípicos:** Se aplicaron tres técnicas: IQR (rango intercuartílico), Z-Score y DBSCAN (detección basada en densidad, multivariable).
- **Transformación de variables continuas y categóricas:** se realizó transformación de variables continuas mediante logaritmo natural, con el objetivo de hacer más homogéneas las variables porque presentaban colas pesadas a la derecha. La variable combustible (Fuel) se transformó en numérica para incluirla en el análisis debido a su importancia en la determinación del precio de un vehículo.

2.3. Herramientas utilizadas

El lenguaje de programación utilizado para el análisis fue Python, mediante librerías importantes como pandas, numpy, seaborn, matplotlib, scikit-learn, scipy, que permitieron la ejecución de las técnicas empleadas. Además de conceptos claves en el curso, como tratamiento de valores atípicos y transformaciones de los datos, ya que esto proporciona mejor análisis de los datos y futuros modelos de predicción.

2.4. Criterios de transformación y limpieza

En la base de datos se encontraron 3.033 vehículos que presentaban iguales características en las variables seleccionadas por ende se tomó la decisión de eliminar estos valores duplicados con el objetivo de que no genere sesgo en el análisis.

En el proceso de preparación de los datos fue necesario aplicar dos transformaciones específicas debido a la naturaleza de las variables y a los requerimientos del análisis posterior.

En primer lugar, se aplicó una transformación logarítmica a las variables continuas altamente asimétricas, especialmente al precio. Este tipo de transformación es ampliamente utilizada cuando la distribución de una variable presenta una cola larga hacia la derecha, grandes diferencias entre valores mínimos y máximos o la presencia de valores extremos que pueden influir de manera desproporcionada en los modelos. La transformación logarítmica tiene como finalidad reducir la asimetría, estabilizar la varianza y atenuar el efecto de los

valores atípicos, permitiendo que las relaciones estadísticas entre variables sean más lineales y que los modelos predictivos basados en regresión o distancias operen de manera más estable y confiable [7].

En segundo lugar, se transformó la variable Fuel (tipo de combustible) en una variable discreta mediante codificación numérica. Esta transformación fue necesaria porque los algoritmos estadísticos y de aprendizaje automático no pueden procesar directamente categorías en formato textual. La codificación asigna un valor entero a cada tipo de combustible sin alterar su significado, permitiendo que la variable pueda ser utilizada en técnicas como análisis multivariado, correlaciones numéricas, modelos de regresión o algoritmos basados en distancias. Además, incluir esta variable en formato numérico permite evaluar su influencia en el precio del vehículo, ya que el tipo de combustible es un factor determinante en aspectos como eficiencia y mantenimiento.

En conjunto, ambas transformaciones contribuyen a mejorar la calidad de los datos, la estabilidad de los análisis y la capacidad predictiva de los modelos, facilitando interpretaciones más robustas y coherentes con el comportamiento real del mercado.

En el presente análisis no se eliminaron los valores atípicos porque, según la naturaleza de los datos y el objetivo del estudio, estos valores no representan errores, sino variaciones reales propias del mercado automotor. En el contexto de precios, kilometraje, potencia o consumo de combustible, los valores extremos suelen corresponder a vehículos de gama alta, autos muy viejos, versiones deportivas, autos con modificaciones de entretenimiento, o condiciones particulares de uso. Por tanto, los atípicos reflejan comportamientos reales del fenómeno estudiado y no deben ser descartados sin un fundamento técnico.

El criterio adoptado se basa en que la eliminación de valores atípicos podría generar una distorsión en la interpretación del mercado, reduciendo artificialmente la variabilidad natural del conjunto de datos y afectando la representatividad del modelo. En lugar de descartarlos, se aplicaron técnicas de transformación como la mencionada (transformación logarítmica) y métodos robustos de escalamiento que permiten mitigar su impacto sin perder información valiosa. Esto garantiza que los modelos estadísticos puedan manejar adecuadamente las diferencias extremas sin comprometer la integridad del análisis.

III. RESULTADOS

3.1. Análisis univariado

Se realiza análisis de las variables continuas, mediante medidas de tendencia Central (Media, Mediana y Moda) y

medidas de dispersión (Rango, Varianza, Desviación estándar y Coeficiente de variación).

El precio de los vehículos, que es la variable de análisis de la base de datos presenta el siguiente comportamiento (Fig.1)




Fig. 1. Histograma de la variable precio.

Entre los hallazgos más importantes de las variables continuas se tiene:

Variable price (precio del auto en euros)

- Media = 18024 y Mediana = 16900; la media es mayor que la mediana lo que determina que la distribución esta sesgada a la derecha.
- La moda es más baja, con un valor de 14990 euros lo que muestra que hay cierta concentración de precios menores al promedio.
- Rango muy grande (4,950 a 74,600) lo que hace referencia a que presenta alta variabilidad.
- El CV es igual a 41%, lo que muestra que la variable presenta una variación moderada alta.
- En el histograma, se observa una concentración importante de precios entre los 10000 y 30000 euros.

Variable km (kilometraje del auto)

- Media = 32090 y Mediana = 20413; la media es mayor que la mediana lo que determina que la distribución está fuertemente sesgada a la derecha.
- La moda es mucho más baja, con un valor de 10 kilómetros lo que muestra que hay cierta concentración de km menores al promedio.
- Rango muy grande (0 a 317,000), presenta muy alta variabilidad.
- El CV tiene un valor de 115%, presenta una variación considerada alta, lo que hace que sea una variable muy dispersa y poco homogénea.
- En el histograma, se observa una concentración importante de km entre los 0 y 50000 km.

Variable hp_kW (Potencia del auto medida en kW)

- Media = 88.5 y Mediana = 85; la variable está bastante centrada por la cercanía entre estas dos medidas, además la moda 85, pero igual presenta sesgo a la derecha
- El Rango va de (40 a 294), presenta baja variabilidad.
- El CV es 30%, presenta una variabilidad moderada.
- En el histograma, se observa una concentración importante de hp_kW entre los 60 y 120.

Variable Displacement_cc (Tamaño del motor en centímetros cúbicos)

- Media = 1429 y Mediana = 1461; valores muy cercanos, lo que da una posible distribución simétrica.
- Rango de (890 a 2967): presenta baja variabilidad.
- El CV es del 30%, presenta una baja variabilidad.
- En el histograma, se observa una concentración importante de Displacement_cc entre los 1152 y 1704, pero con valores significativos menores a 1000.

Variable Weight_kg (Peso del auto en kilogramos)

- Media = 1338 y Mediana = 1295; valores muy cercanos, lo que da una posible distribución simétrica.
- Rango de 840 a 2471, presenta baja variabilidad.
- El CV es del 15%, presenta una baja variabilidad, es decir presenta datos homogéneos.
- En el histograma, se observa una concentración importante de Weight_kg entre los 1100 y 1500 aproximadamente.

Variable cons_comb (Consumo de combustible del auto en litros por cada 100 km)

- Media = 4.83 y Mediana = 4.8; valores muy cercanos, lo que da una posible distribución simétrica.
- Rango de 3 a 9, presenta baja variabilidad.
- Con un CV del 18%, presenta una baja variabilidad, es decir presenta datos homogéneos.
- En el histograma, se observa una concentración importante de cons_comb entre los 4 y 6 aproximadamente.

Además, se realiza análisis de las siguientes características de la distribución de las variables continuas:

1. Asimetría
2. Curtosis

Encontrando que:

TABLA III
DISTRIBUCIÓN VARIABLES CONTINUAS

Variable	Asimetría	Curtosis
price	Sesgo a la derecha	Distribución con colas pesadas
km	Fuerte sesgo positivo	Colas pesadas, posibles outliers
hp_kW	Sesgo a la derecha	Muy leptocúrtica, con valores extremos
Displacement_cc	Casi simétrica	Casi normal
Weight_kg	Sesgo a la derecha	Distribución con colas pesadas
cons_comb	Leve sesgo positivo	Parecida a la normal

Donde podemos evidenciar que todas las variables tienen sesgo a la derecha, y es necesario implementar transformaciones.

Percetiles

Se aplicó análisis de percentiles y se observó que los valores de las variables continuas están en el 90% de los datos, es decir que presentan sesgo a la derecha, que pueden ser valores atípicos, y se necesita más análisis para determinar su tratamiento.

Variables categóricas

Entre las variables de análisis se elige una variable categórica, el tipo de combustible, debido a su importancia en la determinación del precio de los autos:




Fig. 2. Distribución de la variable tipo de combustible.

La mayoría de los vehículos son a gasolina seguido de Diesel, y presentan una pequeña cantidad a gas y a electricidad.

Variables discretas

El análisis arrojó lo siguiente:

- La mayoría de los vehículos tiene 6 transmisiones.
- La edad de los vehículos se distribuye casi homogéneamente de 0 a 3 años.
- La mayoría de los vehículos han tenido un solo

anterior dueño.

- La mayoría de los autos no presentan inspección previa.

3.2. Análisis bivariado

Podemos observar un mayor valor en los autos con menos kilometraje y de tipo de combustible gasolina. (Fig.3)




Fig. 3. Relación entre precio y km por tipo de combustible.

Matriz de correlaciones




Fig. 4. Matriz de Pearson de variables continuas.

Se realizó la matriz de correlaciones de Pearson para las variables continuas (Fig.4) y podemos observar las siguientes relaciones:

El precio(price) presenta:

- Fuerte correlación con potencia hp_kW (0.70): Autos con más potencia suelen ser más caros.
- Correlación media con el peso Weight_kg (0.47): Los autos más pesados tienden a tener mayor precio.
- Correlación baja con Displacement_cc (0.28):

Cilindraje ayuda, pero no explica tanto como la potencia.

EL km (kilometraje) evidencia:

- Correlación negativa con price (-0.40): A más kilometraje, menor precio (esperado en autos usados).
- Correlación negativa con cons_comb (-0.30): Los autos con más km tienden a mostrar menor consumo combinado (posible sesgo por modelos más antiguos).

hp_kW (caballos de fuerza en kW)

- Muy fuerte con Displacement_cc (0.60): A mayor cilindraje, más potencia.
- Fuerte con Weight_kg (0.64): Autos más pesados requieren motores más potentes.

Displacement_cc (cilindraje)

- Moderada con Weight_kg (0.56): Autos más grandes suelen tener motores de mayor cilindraje.

Weight_kg (peso)

- Se asocia moderadamente con price (0.47), hp_kW (0.64) y Displacement_cc (0.56): Autos más pesados tienen más potentes, son más grandes y costosos.

cons_comb (consumo de combustible)

- Débil relación con casi todas, excepto hp_kW (0.39): Los autos con más caballos de fuerza tienden a gastar más combustible.

Coefficiente de correlación de Pearson: Mide la fuerza y dirección de la relación lineal entre dos variables cuantitativas.

TABLA IV
COMPARACIÓN CON PRECIO

Variable con price	Coefficiente de Pearson
km	-0.4
hp_kW	0.7
Displacement_cc	0.28
Weight_kg	0.47
cons_comb	0.27

En primer lugar, la variable kilometraje (km) presenta una correlación negativa moderada ($r = -0.40$), lo que indica que, a medida que aumenta el kilometraje recorrido, el precio del vehículo tiende a disminuir. Este resultado es consistente con la depreciación natural asociada al uso del automóvil.

Por otro lado, la potencia del motor (hp_kW) muestra una correlación positiva fuerte ($r = 0.70$), evidenciando que los vehículos con mayor potencia suelen tener precios más

elevados, lo cual es coherente con la relación esperada entre rendimiento y valor comercial. Asimismo, variables como el cilindraje (Displacement_cc) ($r = 0.28$) y el peso del vehículo (Weight_kg) ($r = 0.47$) presentan correlaciones positivas débiles a moderadas, lo que sugiere que, aunque los autos más grandes o pesados tienden a tener precios superiores, la relación no es tan determinante como la potencia. Finalmente, el consumo de combustible (cons_comb) muestra una correlación positiva débil ($r = 0.27$), posiblemente asociada al hecho de que los motores más potentes y de mayor cilindrada suelen tener mayor consumo.

En conjunto, los resultados indican que la potencia del motor constituye el factor más influyente sobre el precio, mientras que el kilometraje actúa en sentido opuesto, reduciendo significativamente el valor del vehículo. Las demás variables contribuyen en menor medida a explicar la variación del precio en el mercado analizado.

Chi-cuadrado de independencia

Interpretaciones variables cualitativas: Todas las variables discretas están estrechamente relacionadas entre sí. Esto indica que la edad del vehículo y su número de dueños influyen en sus características de transmisión y estado de inspección, lo que refleja patrones consistentes en el mercado automotriz.




Fig. 5. Chi cuadrado entre edad y dueños previos.

3.3. Análisis multivariado

Las variables se analizan mediante:

- Análisis de Componentes Principales (ACP / PCA)
- Regresión Múltiple
- Análisis de Clúster (Cluster Analysis)
- Análisis Factorial

3.3.1. Análisis de Componentes Principales (PCA)

TABLA V
PORCENTAJES DE COMPONENTES

Varianza explicada por componente (%):

PC1: 45.64%

PC2: 26.53%

PC3: 12.79%

PC4: 6.80%

PC5: 5.82%

PC6: 2.42%

PC1 (45.64%): El primer componente principal explica casi la mitad de la variabilidad total del conjunto de datos, lo que sugiere que existe una combinación lineal de variables que resume gran parte de la información original.

PC2 (26.53%): El segundo componente añade un 26.53% adicional, lo que eleva la varianza acumulada a 72.17%. Con los dos primeros componentes se explica más del 70% de la variabilidad total, lo cual es un resultado muy bueno en análisis multivariado.

PC3 (12.79%): Con el tercer componente se alcanza aproximadamente 85% de la varianza total explicada, lo que indica que las tres primeras componentes contienen prácticamente toda la estructura informativa relevante.

PC4 a PC6 (menores al 7%): Los últimos componentes aportan una cantidad pequeña de varianza, por lo que pueden considerarse menos relevantes o incluso prescindibles si el objetivo es simplificar el modelo.

Las ecuaciones de los componentes principales muestran qué tanto contribuye cada variable original a cada componente (auto vector). El signo (positivo o negativo) indica el sentido de la relación, y el valor absoluto indica la fuerza de la contribución.

Los dos principales componentes explican:

$$PC1 = 0.467 * price - 0.032 * km + 0.562 * hp_kW + 0.423 * Displacement_cc + 0.479 * Weight_kg + 0.238 * cons_comb$$

Este componente está dominado por las variables `hp_kW`, `Weight_kg`, `price` y `Displacement_cc`, todas con coeficientes positivos altos. Representa una dimensión de potencia y tamaño del vehículo. Cuanto mayor sea el valor del PC1, mayor es el rendimiento del vehículo (más caballos de fuerza, más peso y mayor cilindraje).

$$PC2 = -0.314 * price + 0.701 * km - 0.007 * hp_kW + 0.398 * Displacement_cc + 0.230 * Weight_kg - 0.445 * cons_comb$$

Aquí destaca `km` (kilometraje) con un peso positivo alto (0.701) y `cons_comb` (consumo) con un peso negativo (-0.445). Este componente parece medir una dimensión de uso y eficiencia: vehículos con alto kilometraje y bajo consumo de combustible.




Fig. 6. Porcentaje de explicación de los PCA.

Al analizar la gráfica de varianza explicada acumulada, se observa que los dos primeros componentes principales (PC1 y PC2) concentran más del 70% de la variabilidad total de los datos, lo que indica que gran parte de la información contenida en las variables originales puede resumirse adecuadamente en un plano bidimensional. Asimismo, al incorporar el tercer componente (PC3), la varianza acumulada supera el 80%, reforzando que los tres primeros componentes capturan la mayoría de la estructura subyacente del conjunto de datos, reduciendo significativamente la dimensionalidad sin una pérdida importante de información.

La matriz de correlaciones entre los componentes principales muestra que todas las correlaciones fuera de la diagonal son prácticamente nulas (valores cercanos a cero). Esto indica que los componentes principales son mutuamente independientes y ortogonales, cumpliendo con la propiedad fundamental del PCA de generar nuevas variables no correlacionadas. Por tanto, cada componente explica una porción distinta y no redundante de la variabilidad total del conjunto de datos.

3.3.2. Supuestos de regresión Múltiple

Se analizaron los supuestos de la regresión lineal múltiple:

Linealidad

Algunas relaciones podrían no ser puramente lineales, es necesario realizar transformaciones logarítmicas, para cumplir con este supuesto

Homoscedasticidad

Se detecta heterocedasticidad, se recomienda ajustar el modelo utilizando errores robustos o aplicar transformaciones a la variable dependiente para estabilizar la varianza.

Normalidad

No se cumple el supuesto de normalidad, se ve necesario realizar transformaciones de las variables originales

Multicolinealidad

TABLA VI
VALORES VIF DE LAS VARIABLES CONTINUAS

Factores de inflación de varianza (VIF):

	Variable	VIF
0	const	99.259946
1	km	1.252306
2	hp_kW	2.559685
3	Displacement_cc	1.962765
4	Weight_kg	1.900706
5	cons_comb	1.382357

Las variables predictoras no tienen multicolinealidad problemática. Todos los VIF son menos de 3, muy por debajo del umbral de 5, las variables son relativamente independientes entre sí.

3.3.3. Clúster

Tanto el clúster jerárquico como K-Means formaron 3 grupos claros.




Fig. 7. Clúster jerárquico de los 2 primeros componentes.

Los grupos se diferencian principalmente por: potencia (hp_kW), kilometraje (km), peso del vehículo (Weight_kg), y precio.

3.3.4. Análisis factorial

TABLA VII
ANÁLISIS FACTORIAL

♦ CARGAS FACTORIALES:			
	Factor 1	Factor 2	Factor 3
price	0.602	0.795	0.056
km	0.221	-0.653	-0.204
hp_kW	0.852	0.208	0.260
Displacement_cc	0.757	-0.216	-0.005
Weight_kg	0.746	0.024	0.001
cons_comb	0.111	0.192	0.973

♦ VARIANZA EXPLICADA:			
	Varianza	Proporción	Acumulada
Factor 1	2.279	0.380	0.380
Factor 2	1.186	0.198	0.578
Factor 3	1.059	0.176	0.754

Cada factor agrupa variables con altas cargas:

Factor 1: Desempeño del vehículo: Altas cargas en: hp_kW (0.852), Displacement_cc (0.757), Weight_kg (0.746) y price (0.602); Representa potencia y características físicas asociadas al desempeño y costo.

Factor 2: Uso y kilometraje: Cargas destacadas: price (0.795) positiva y km (-0.653) negativa; los autos más nuevos o menos usados valen más.

Factor 3: Carga casi exclusiva de cons_comb (0.973); representa eficiencia o consumo de combustible, independiente de potencia o uso.

3.4. Detección de outliers

La técnica de Z-Score detectó pocos atípicos extremos (valores muy altos de precio o kilometraje) Fig. 8




Fig. 8. Técnica de Z-score para valores atípicos en precio.

La técnica IQR mostró más observaciones atípicas, especialmente en km. Fig. 9




Fig. 9. Técnica de IQR para valores atípicos en precio.

La tercera técnica utilizada DBSCAN identificó puntos de baja densidad como autos “extremos”, posiblemente de lujo o muy deteriorados.

Observaciones sobre valores atípicos:

- price y km son las variables con mayor presencia de outliers.
- Muchos de estos valores no son errores, sino autos especiales (de alta gama o muy usados).
- hp_kW, Weight_kg y Displacement_cc muestran distribuciones más homogéneas.

Tratamiento de valores atípicos:

Autos de lujo o deportivos (precios muy altos, alta potencia): se deben mantener puesto que, representan una categoría válida del mercado.

Kilometrajes extremadamente altos: como son reales, pueden mantenerse; o se puede intentar transformar con (log).

Conclusión del análisis de outliers: No deben eliminarse automáticamente; algunos representan segmentos reales del mercado (lujo o deterioro severo). Solo se eliminan si interfieren con un modelo predictivo.

3.5 Proceso Limpieza de los datos

En este proceso, se realizaron 4 etapas:

1. Detección de valores faltantes
2. Eliminación de duplicados
3. Filtrado y tratamiento de valores atípicos (outliers)
4. Validación posterior a la imputación

3.5.1. Detección de valores faltantes: la base de datos seleccionada no presenta valores faltantes, por ende, no es necesario realizar estrategias de imputación.

3.5.2. Eliminación de duplicados: se identificaron y eliminaron 3033 registros duplicados, con el fin de garantizar la integridad del análisis.

3.5.3. Filtrado y tratamiento de valores atípicos (outliers): Como se planteó desde el principio, los valores atípicos son normales en la base de datos, puesto que los precios pertenecen a los vehículos de alta gama y el kilometraje alto también es normal debido a vehículos de pruebas que están a la venta en la plataforma. Por el momento se continúan con los valores atípicos y se busca realizar una transformación

3.5.4. Validación posterior al tratamiento de datos faltantes y duplicados

En este proyecto no fue necesario aplicar técnicas de imputación, ya que el conjunto de datos no presentaba valores faltantes relevantes.

Para evaluar si la eliminación de duplicados generó alteraciones en la distribución de las variables continuas, se realizó una validación gráfica comparativa, utilizando histogramas antes y después del proceso de depuración.

Los resultados muestran que las distribuciones mantienen su forma general, sin cambios significativos en tendencia central o dispersión. Esto confirma que la eliminación de duplicados no introduce sesgos y que las características estadísticas de la base de datos se preservan.




Fig. 10. Histograma de precio antes y después de la eliminación.

Se observa que la variable después de la eliminación de duplicados tiene el mismo comportamiento original.

3.6. Transformaciones

Se utiliza la técnica de Escalamiento Robusto (Robust Scaling), debido a los valores atípicos presentes en la variable precio




Fig. 11. Escalamiento robusto de la variable precio.

El escalamiento robusto preserva la forma de los datos sin que los outliers distorsionen el rango.

A diferencia de la estandarización tradicional, este método no se ve afectado por la presencia de outliers, lo que lo hace especialmente útil cuando los datos presentan distribuciones sesgadas o colas largas a la derecha como es el caso de la variable de estudio el precio.

Transformación logarítmica

Se elige la transformación logarítmica porque es una técnica clásica utilizada para reducir la asimetría positiva (sesgo a la derecha) en distribuciones donde existen valores muy grandes en comparación con el resto de los datos. En la base de datos todas las variables continuas tienen sesgo a la derecha.




Fig. 12. Transformación logarítmica de la variable precio.

Tras aplicar la transformación $\log(x + 1)$ a las variables continuas del conjunto de datos, se observa una mejora general en la forma de las distribuciones. En casi todas las variables, la transformación reduce la asimetría positiva, comprime los valores extremos y acerca la distribución a una forma más simétrica. Esto favorece los supuestos de normalidad utilizados en varios métodos estadísticos y mejora el comportamiento de los modelos predictivos.

La transformación logarítmica fue efectiva para todas las variables continuas:

- Reduce asimetría y curtosis
- Comprime valores extremos
- Mejora la forma de las distribuciones
- Prepara mejor los datos para PCA, regresión y clustering
- Reduce la influencia de outliers sin eliminarlos

V. CONCLUSIONES

Se identificaron las tendencias de las variables continuas y discretas en la base de datos de estudio:

- El precio promedio de los autos es de 18.024 dólares.
- La mayoría de los precios se encuentran entre 10.000 y 30.000 dólares.
- La mayoría de los autos tienen entre 0 a 50.000 km.
- El tipo de combustible predominante es la gasolina, seguido por el diésel.
- La edad de los vehículos se distribuye casi uniformemente igual entre las edades de 0 a 3 años.
- La mayoría de los autos son usados.

La base de datos presenta limitaciones, puesto que no incluye información detallada sobre el estado real del vehículo como accidentes o mantenimiento realizados. Por otro lado, puede haber un sesgo hacia ciertas regiones donde la

compañía AutoScout24 tiene más presencia. Además, los precios corresponden a anuncios, no necesariamente a precios finales de venta, y no se especifica si los autos nuevos provienen de concesionarios oficiales o vendedores particulares.

El análisis exploratorio inicial permitió comprender la estructura y comportamiento general del conjunto de datos.

- Los autos más nuevos presentan precios considerablemente más altos.
- Los vehículos utilizan primordialmente gasolina y diesel; una proporción muy pequeña gas y electricidad.
- A mayor edad del auto, menor es el precio de venta, lo que se observa con la relación negativa entre el precio y la edad del vehículo.
- Se identificó una relación negativa entre el kilometraje y el precio de los vehículos, lo que confirma que el desgaste por uso reduce el valor de mercado

Las variables continuas como price, km, hp_kW, Displacement_cc, Weight_kg y cons_comb mostraron una amplia variabilidad, evidenciando la diversidad de vehículos en el mercado (desde autos económicos hasta de alta gama).

Las variables continuas que más influyen en el precio son la potencia del motor (hp_kW), el kilometraje y el peso del vehículo.

Se identificó una distribución asimétrica positiva en variables como price y km, lo que indica la presencia de vehículos con precios o kilometrajes excepcionalmente altos.

Por su parte, las variables discretas (Gears, age, Previous_Owners, Inspection_new) mostraron concentraciones en pocos valores, lo cual sugiere que la mayoría de los vehículos tienen configuraciones y estados relativamente similares.

Las variables discretas están asociadas entre sí, especialmente las relacionadas con edad del auto, número de dueños y estado de inspección.

El Análisis de Componentes Principales (PCA) permitió reducir la dimensionalidad del conjunto de variables continuas. Los dos primeros componentes principales explicaron más del 70% de la varianza total, lo cual indica que gran parte de la información puede resumirse en pocas dimensiones.

El PCA reveló una estructura interna sólida, donde dos componentes explican más del 70% de la variabilidad. Esto indica que el conjunto de datos tiene redundancia y permite una reducción dimensional efectiva.

El análisis de clúster identificó patrones diferenciados en el mercado: autos económicos, intermedios y de gama alta.

Se aplicaron los métodos IQR (rango intercuartílico) y Z-Score, además de DBSCAN para identificar observaciones atípicas multivariadas.

Los resultados mostraron outliers principalmente en las variables price y km, correspondientes a vehículos de lujo o con kilometraje extremo.

La detección de valores atípicos permitió identificar autos extremadamente caros, muy usados o de características únicas; estos valores deben tratarse según el objetivo (descriptivo vs predictivo).

En el proceso de limpieza de datos, no se encontró ausencia de datos por tanto no era necesario realizar técnicas de imputación.

En transformación se utilizó logaritmo natural con el objetivo disminuir la presencia de valores atípicos.

El estudio proporciona una base sólida para análisis posteriores como modelos de predicción del precio o segmentación del mercado.

REFERENCIAS

- [1] Grand View Research, *Used Car Market Size, Share & Trends Analysis Report*, 2025.
- [2] Y. Iitturan, *Auto Scout Car Price [Dataset]*. Kaggle, 2019. Disponible en: <https://www.kaggle.com/datasets/yaaryiitturan/auto-scout-car-price>
- [3] S. Muti and M. Yildiz, "Using Linear Regression for Used Car Price Prediction," *Dergipark Journal*, 2023. [Online]. Available: <https://dergipark.org.tr/en/download/article-file/2242032>
- [4] S. Kumar and A. Sinha, "Predicting Used Car Prices with Regression Techniques," *International Journal of Computer Trends and Technology (IJCTT)*, vol. 72, no. 6, pp. 132–141, 2024, doi: 10.14445/22312803/IJCTT-V72I6P118.
- [5] Y. Turan, "Analysis of Circular Price Prediction Strategy for Used Electric Vehicles," *Sustainability*, vol. 16, no. 13, 5761, 2023. [Online]. Available: <https://www.mdpi.com/2071-1050/16/13/5761>
- [6] *Machine Learning for Predicting Used Car Resale Prices Using Granular Vehicle Equipment Information, Expert Systems with Applications*, Elsevier, 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0957417424025077>
- [7] R. J. Larsen and M. L. Marx, *An Introduction to Mathematical Statistics and Its Applications*, 5th ed. Pearson, 2012.
- [8] W. McKinney, "Data structures for statistical computing in Python," in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 51–56.
- [9] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [10] M. Waskom, "Seaborn: Statistical data visualization," *Journal of Open Source Software*, vol. 6, no. 60, p. 3021, 2021.